



- 刘刚, liugang@ict.ac.cn, 微信号: wuhanliugang
- •廖攀, liaopan15@mails.ucas.ac.cn, 微信号: reallocing
- •冷佳旭, 442675812@qq.com, 微信号: leng292099
- 主要负责上机管理

大数据系统与大规模数据分析

@2015-2018 陈世敏(chensm@ict.ac.cn)

微信群





该二维码7天内(3月31日前)有效,重新进入将更新

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

上机安排(1)

- 地点
 - □计算机学院,4层
 - □网络安全教学实验室(447室):50台
 - □云计算教学实验室(432室):20台
- 机器: 联想PC机M6400t, Windows 7/32bit
 - 环境:每台机器安装了一个虚拟机,运行Ubuntu Linux14.04.2, JDK 1.7, Hadoop 2.6.0, HBase 0.98等
 - □本作业只需要在单机上构成伪分布环境
- •注:可以在自己的计算机上完成作业

大数据系统与大规模数据分析

@2015-2018 陈世敏(chensm@ict.ac.cn)

上机安排(2)

- 时间
 - □周五上午,8:30-11:50am
 - □周五下午, 1:00-4:20pm
- 上机期间助教的职责
 - □**管理上机秩序:** 上机前找助教签到,分配机器;使用完毕, 找助教签出;助教负责监督机房秩序(不得喧哗、打闹等)。
 - □解答机器使用的问题: 包括如何开机、如何登录、如何 使用编辑器、如何编译和运行程序
 - □不包括: 其它关于作业内容的问题

大数据系统与大规模数据分析

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

©2015-2018 陈世敏(chensm@ict.ac.cn)

作业时间安排 周次 作业 第4周, 3月28日 大数据存储系统1:基础,文件系统, HDFS 作业1布置 第5周, 4月4日 大数据存储系统2:键值系统 第6周,4月11日 大数据运算系统1: MapReduce,图计算系统 作业2布置 最邻近搜索和位置敏感 (LHS) 哈希算法 第7周,4月18日 作业1提交 第8周,4月25日 大数据存储系统3:图存储, document store 第9周,5月2日 大数据运算系统2:图计算系统, MR+SQL 大数据运算系统3: 内存计算系统 作业2提交, 第10周,5月9日 大作业布置 第11周,5月16日 数据空间的维度约化 第12周,5月23日 推荐系统 作业3 第13周,5月30日 流数据采样与估计、流数据过滤与分析 第14周,6月6日 教育大数据的建模与分析 第15周,6月13日 期末考试 大作业验收 第16周,6月20日 大作业验收报告

课程相关

- 成绩分配
 - □闭卷考试: 50%
 - □作业1+作业2+作业3: 30%
 - □大作业: 20% □课堂表现: +5%

大数据系统与大规模数据分析

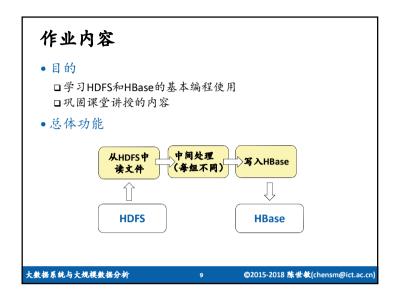
©2015-2018 陈世敏(chensm@ict.ac.cn)

作业1安排

- 成绩: 占总成绩10%
- 时间
 - □发布: 2018/3/28(Wed)
 - □上交: 2018/4/18(Wed), 北京时间 6:59pm (共3周)
 - □在课程系统中提交
 - □晚交
 - 最晚: 2018/4/25(Wed), 北京时间 6:59pm, 将扣除20%成绩
 - 之后不再接收,作业1成绩为0
- 抄袭:课程总分为0!

大数据系统与大规模数据分析

@2015-2018 陈世敏(chensm@ict.ac.cn





分组 ●共分为6个组,每个组的作业题目有一定区别 ●分组方式如下 □组号=(学号最右面6位数字)%6 □%是求余数 ●举例 □学号=201618013229032 □学号最右面6位数字=229032 □组号=229032%6=0 □所以是第0组



从HDFS中 读文件 (李组不同) →写入HBase 写入HBase Д Û HDFS HBase • (这部分在第5周会仔细讲解) •本次作业的输出写入HBase, 表名是Result, 注意大小写 • 给定了表名 □首先检查这个表是否存在, 如果存在, 那么删除 □创建Result表 □把结果写入 大数据系统与大规模数据分析 ©2015-2018 陈世敏(chensm@ict.ac.cn)

```
hbase shell
  create 'mytable', 'mycf'
       创建表, column family
  put 'mytable', 'abc', 'mycf:a', '123'
  0 row(s) in 0.0580 seconds
  put 'mytable', 'def', 'mycf:b', '456'
  0 row(s) in 0.0060 seconds
  scan 'mytable'
  ROW
            COLUMN+CELL
   abc
            column=mycf:a, timestamp=1427731972925, value=123
            column=mycf:b, timestamp=1427731990058, value=456
  2 row(s) in 0.0300 seconds
大数据系统与大规模数据分析
                                           ©2015-2018 陈世敏(chensm@ict.ac.cn
```

举例: HBase create table & Put

```
public class HBaseTest {
   public static void main(String[] args) throws MasterNotRunningException,
ZOOKeeperConnectionException, IOException {
      // create table descriptor
      String tableName= "mytable";
      HTableDescriptor htd = new HTableDescriptor(TableName.valueOf(tableName));

      // create column descriptor
      HColumnDescriptor cf = new HColumnDescriptor("mycf");
      htd.addFamily(cf);

      // configure HBase
      Configuration configuration = HBaseConfiguration.create();
      HBaseAdmin hAdmin = new HBaseAdmin(configuration);

      hAdmin.createTable(htd);
      hAdmin.close();
```

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

中间处理

第0组	Hash join
第1组	Sort-merge join
第2组	Hash based group-by
第3组	Sort based group-by
第4组	Hash based distinct
第5组	Sort based distinct

注:

- 假设所有数据都可以放入内存
- 可以采用Java已有的库实现hash table和sorting

大数据系统与大规模数据分析

@2015-2018 陈世敏(chensm@ict.ac.cn)

举例: HBase create table & Put

```
// put "mytable", "abc", "mycf:a", "789"

HTable table = new HTable(configuration, tableName);
Put put = new Put("abc".getBytes());
put.add("mycf".getBytes(), "a".getBytes(), "789".getBytes());
table.put(put);
table.close();
System.out.println("put successfully");
}
```

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

第0组/第1组: Join

- 命令行:
- □ java Hw1GrpX R=<file 1> S=<file 2> join:R2=S3 res:R4,S5 □ 蓝色是可变的参数、X=0或X=1
- 输入hdfs文件: <file 1>, <file 2>
 - □ 例如: /hw1/lineitem.tbl等
- Join key: 每个文件有一列为join key
 - □ 例如: R的第2列和S的第3列 (从第0列数起)
- 输出: 可以有1到多列
 - □ 在HBase中,建立名为Result的表,row key是join key,column family是res,column是R4和S5,value是相应的值
 - 例如: 一个结果join key= abc, R4= def, S5= ghi 那么在HBase的Result表中, 需要有(row key=abc, res:R4=def) (row key=abc, res:S5=ghi)
- 如何实现join? 见讲义

大数据系统与大规模数据分析

@2015-2018 陈世敏(chensm@ict.ac.cn

相同join key的输出

- 例如:
 - □结果包含:
 - join key= abc, R4= def, S5= ghi
 - join key= abc, R4= 123, S5= 456
 - join key= abc, R4= 789, S5= ghi
 - □那么输出到Hbase:
 - (row key=abc, res:R4=def) (row key=abc, res:S5=ghi)
 - (row key=abc, res:R4.1=123) (row key=abc, res:S5.1=456)
 - (row key=abc, res:R4.2=789) (row key=abc, res:S5.2=ghi)

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

举例

R0	R1	R2	R3	R4	R5
100	3	good	nice	ok	12
101	6	abc	def	better	10
102	9	abc	def	best	10
103	12	abc	def	nicest	8

java Hw1GrpX R=<file> groupby:R2 res:count,avg(R5),max(R0)

- 第0个结果(abc, 3, 9.33,103), 那么在HBase的Result表中有 (row key=abc, res:count=3) (row key=abc, res:avg(R5)=9.33) (row key=abc, res:max(R0)=103)
- 第1个结果(good, 1,12,100), 那么在HBase的Result表中有 (row key=good, res:count=1) (row key=good, res:avg(R5)=12) (row key=good, res:max(R0)=100)

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

第2组/第3组: Group-by

- □ java Hw1GrpX R=<file> groupby:R2 res:count,avg(R3),max(R4) □ 蓝色是可变的参数, X=2或X=3
- 輸入文件: <file>
 - □ 例如: /hw1/lineitem.tbl
- Group by key: 只有一列
 - □例如: R的第2列 (从第0列数起)
- 输出: 可以有1~多列, 数值列
 - □ 三种形式为(a) count, (b) avg(列), (c) max(列)
 - □ 在HBase中、建立名为Result的表, row key是group by key, column family是res, column是count、avg(R3)、max(R4), value是相应的值
 - □ 例如: 一个结果groupby key= abc, count=3, avg(R3)= 10, max(R4)=20 那么在HBase的Result表中, 需要有(row key=abc, res:count=3) (row key=abc, res:avg(R3)=10) (row key=abc, res:max(R4)=20)
- 注: count和max结果是准确值, avg保留小数点后2位数

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

Group by实现

- Hash based
 - □建立一个hash table
 - □ Key= group by key
 - □Value= 需要统计的信息
 - Count: 目前的计数
 - Avg: 目前的sum和count
 - Max: 目前的最大值
 - □把输入都使用hash table完成统计,最后扫描输出hash table中的所有项
- Sort based
 - □根据group by key 排序
 - □然后同一个group的都会在一起
 - □统计输出

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn

第4组/第5组: Distinct

- 命今行:
 - □ java Hw1GrpX R=<file> select:R1,gt,5.1 distinct:R2,R3,R5 □ 蓝色是可变的参数、X=4或X=5
- 输入文件: <file>
 - □ 例如: /hw1/lineitem.tbl等
- 选择: 只有一列, 数值列
 - □ 6种形式(a)列,gt,值,(b)列,ge,值,(c)列,eq,值,(d)列,ne,值, (e)列,le,值,(f)列,lt,值
 - □ 涵义: >gt; >= ge; == eq; != ne; le <=; lt <
 - □例如: R的第1列大于5.1 (从第0列数起)
- 输出: 可以有1~多列
 - □ 每种组合只输出一次
 - □ 在HBase中,建立Result表, row key是序号, column family是res, column是R2,R3和R5, value是相应的值

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

Distinct实现

- Selection: 每个记录依次进行比较
- Hash based
 - □建立一个hash table
 - □ Key= distinct所有key (例如: R2,R3,R5)
 - ロ Value= 空
 - □把輸入都放入hash table一次且仅一次,最后扫描輸出 hash table中的所有项
- Sort based
 - □根据distinct key 排序
 - □然后相同的都会在一起
 - □输出

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

举例

R0	R1	R2	R3	R4	R5
100	3	good	nice	ok	12
101	6	abc	def	better	10
102	9	abc	def	best	10
103	12	abc	def	nicest	8

java Hw1GrpX R=<file> select:R1,gt,5.1 distinct:R2,R3,R5

- 第0个结果(abc, def, 10), 那么在HBase的Result表中,需要有 (row key=0, res:R2=abc) (row key=0, res:R3=def)(row key=0, res:R5=10)
- 第1个结果(abc, def, 8), 那么在HBase的Result表中,需要有 (row key=1, res:R2=abc) (row key=1, res:R3=def)(row key=1, res:R5=8)

大教据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

以TPCH数据为基础的例子

- Join
 - □ java Hw1Grp0 R=/hw1/lineitem.tbl S=/hw1/orders.tbl join:R0=S0 res:S1,R1,R5
 - □ java Hw1Grp1 R=/hw1/lineitem.tbl S=/hw1/part.tbl join:R1=S0 res:S1,S3,R5
- Groupby
 - □ java Hw1Grp2 R=/hw1/lineitem.tbl groupby:R2 res:count,max(R5)
 - ☐ java Hw1Grp3 R=/hw1/orders.tbl groupby:R1 res:count,avg(R3)
- Distinct
 - □ java Hw1Grp4 R=/hw1/part.tbl select:R7,gt,1800 distinct:R3,R4,R5
 - □ java Hw1Grp5 R=/hw1/lineitem.tbl select:R4,lt,5 distinct:R13,R14,R8,R9

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn

作业提交的格式

- 文件命名
 - □ 组号_学号_hw1.java
 - □ 例如: 0 201618013229032 hw1.java
 - □注意:上述文件名没有空格;不能上传rar或zip文件
- 程序中Java class的名字必须为
 - □ Hw1GrpX, 其中X为组号, 注意大小写
 - □ 例如: Hw1Grp0
- 自动检查程序会根据学号自动寻找对应的文件, 重新命名为 Hw1GrpX,iava、编译、执行

29

- □如果名称不正确,将无法找到或不能执行,就成绩=0
- □ 注意在jdk 1.7, hadoop 2.6, hbase 0.98环境下可以正确编译执行

大教据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

错误的class名举例

- x public class hw1group {
- X public class hw1 {
- X public class Hw1Group2 {
- X public class Hw1Grp9{
- X public class MyTest {

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

错误的文件名举例

- X 0 201018013229032 hw1.java
- X 0 201018013229032 hw1 .java
- X 0 201018013229032 hw1.java.java
- X 0_201018013229032_hw1.rar
- X 0 201018013229032 hw1.zip
- X Hw1Grp0.java
- X 0 201018013229032 hw0.java

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn)

注意事项

- •命名
 - □程序名、类名、表名、Column Family名、列名等 □注意大小写,必须按照规定
- •程序注释
 - □注意程序格式,要求有Javadoc要求的注释,没有就-1

30

- □只能用英文
- 仅提交一个Java文件,不能附带其他jar包
- 严禁抄袭
 - □会有自动检查程序(也会比较去年的作业)
 - □一旦发现,抄袭各方课程总成绩均为0分

大数据系统与大规模数据分析

©2015-2018 陈世敏(chensm@ict.ac.cn